

# **Laboratorio de Datos:** **Verano - 2025**

## **Trabajo Práctico 02**

Nombre del grupo: Alc boys

Integrantes:

- Dalmiro Paz Ludueña
- Gonzalo Nicolas Ser
- Julián Ignacio Clement

## Resumen:

En el presente informe se buscó profundizar en los aspectos de análisis exploratorio, clasificación binaria, selección de atributos y clasificación multiclase de la fuente de datos mnist. Se encontró que atributos tienen mayor impacto en la identificación de los dígitos, porque unos son más importantes que otros, como importan la cantidad de píxeles tomados, por qué hay dígitos más distintivos que otros y que tan bien pueden ser predichos estos mismos.

## Introducción:

A lo largo del informe se utilizaron herramientas tales como consultas SQL, gráficos, KNN, métricas como exactitud, precisión y recall, árboles de clasificación, k-folding.

En cuanto al análisis exploratorio este se orientó en identificar qué atributos son los más importantes a la hora de diferenciar unos dígitos con otros y que píxeles son irrelevantes a la hora de manipular la fuente de datos.

Por otro lado en la clasificación binaria y selección de atributos se hizo énfasis en la distinción de dígitos, en particular del 0 y 1. Empleando estas clases se puso foco en usar los píxeles más diferenciables, hallando la gran influencia que tenían estos en el modelo. A la vez mediante el modelo de KNN también se contempló la poca influencia que tuvo la variación del número de vecinos.

Por último en relación a la clasificación de multiclase se buscó analizar que tan buen rendimiento tenía este a la hora de clasificar por dígito según la imagen recibida, obteniendo con una profundidad 10 (hiperparámetro más alto) un porcentaje cercano al 65%, lo cual indica que si bien en la mayoría de casos identifica correctamente también posee una tasa de error a considerar. Por otro lado, la matriz de confusión fue una herramienta que se usó de guía a la hora de determinar las clases que más se distinguían de otras. Se concluyó que este no es el mejor tipo de modelo para predecir el conjunto de datos dado.

## Análisis Exploratorio:

Tras inspeccionar el data frame del MNIST se hallaron 70 mil datos y un total de 786 columnas, las cuales se dividen entre: 'Unnamed: 0', indicando el index de cada dato y 'labels' que referencia al dígito que hace referencia el dato; las demás columnas son nombradas como números del 0 al 783 identificando la posición del píxel donde se guardará la intensidad de color en un tono del 0 al 255 (0 = negro, 255 = blanco). Cada fila representa una imagen de 28x28, es decir 784 píxeles, en escala de grises para plasmar en una imagen el dígito a representar escrito a mano.

Por otro lado la cantidad de dígitos a representar fueron 10, donde se encuentran el 0, 1, 2, 3, 4, 5, 6, 7, 8 y 9. Fueron elegidos ya que con estos puede representarse todo número entero, a través de identificar todos los números enteros que puedan haber en un registro escrito a mano.

También es importante destacar que en un primer momento se creía que la cantidad de casos de representación serían iguales para todos los dígitos, sin embargo se encontró que algunos poseían mayor cantidad de filas que otros.




Figura 1: Cantidad de representaciones de cada dígito

a) Al momento de analizar qué atributos podrían ser de interés y cuáles no, se entiende que deben de ser aquellos que identifiquen los píxeles que contienen información relevante para diferenciar las clases. Como primera idea se realizó un promedio de intensidades de cada píxel a lo largo de todas las imágenes disponibles, independientemente de la clase, con la siguiente hipótesis: “Por la morfología de los números, los bordes de las representaciones aportarán menor información para discernir la clase en comparación con el centro”, idea que se ve en la Figura 1.

Es importante remarcar que se optó por usar la media ya que los valores de intensidad van del 0 al 255, estableciendo esta característica acotada superior e inferiormente. Por lo tanto, el promedio no podría ser afectado por valores atípicos, transformándose en una métrica confiable.




Figura 2: Promedio de intensidad por píxel de todas las clases, Figura 3: Píxeles con un promedio menor a 100 y Figura 3: Píxeles con un promedio mayor a 100.

En las figuras se observa como los trazos de los números tienen algunas áreas más comunes que otras, verificando que lo relevante para identificar un número sucede en los píxeles internos que externos. Por lo tanto, se propuso elegir una intensidad arbitraria para decidir si un píxel era importante o no, siendo así, como se ve en la Figura 2, los píxeles que mantienen una intensidad por debajo del umbral y, por ende, pudiendo ser descartados.

Luego, por último, en la Figura 3 se puede observar los píxeles que se consideran relevantes. De esta forma, al basar el trabajo en este planteo, se pasaría a utilizar tan solo el 41% de los píxeles totales.

b) En principio, se planteó la siguiente hipótesis a contrastar: “Números con morfologías similares compartirán una mayor cantidad de píxeles”. Para llevar a cabo el ejercicio se ha buscado desarrollar una forma de diferenciar los números de forma algorítmica, con una serie de pasos que se podrán ver en el código de forma detallada, para permitir su reproducción y no caer en subjetividades.

Primero se buscó el promedio - con el mismo método que el ejercicio anterior - de cada número de interés. Se guardó la ubicación de aquellos píxeles con cierto grado de luminosidad arbitraria, de forma tal que sea lo más relevante posible sin perder la forma de los números. Aquí los resultados:




Figura 4: Píxeles promedios de los números 1, 3 y 8 con un promedio mayor a 120.

Luego se filtraron aquellos píxeles que solamente aparecen en un de las clases, es decir, si un píxel aparece en dos números o más, no será tomado en cuenta; como se observa en la Figura 5 tanto para la comparación del 1 con el 3 (los dos gráficos de la izquierda) como del 3 con el 8 (los dos de la derecha). Y, también, aquellos píxeles que son compartidos entre todos los números de interés.




Figura 5: Píxeles promedios únicos entre el 1 y 3 (izquierda), y, entre 3 y 8 (derecha).

Estos pasos nos llevaron a los siguientes resultados:

- El 1 y 3 tienen 23 y 86 píxeles únicos, respectivamente. Mientras que comparten 39 píxeles.
- El 3 y 8 tienen 37 y 65 píxeles únicos, respectivamente. Mientras que comparten 88 píxeles.

Se observa que los números 3 y 8, números con un trazo similar, comparten una cantidad de píxeles mayor que entre el 1 y 3. De todas formas, si bien se pierden muchos píxeles al comparar el 3 con el 8, se ve que la cantidad total de píxeles que permiten diferenciar ambos números son: 109 para el 1 y el 3, y, 102 para el 3 y el 8. Es decir, son cantidades similares. Esto puede deberse a que el trazo del 8 es de mayor recorrido por lo que abarca más píxeles que el 1. Aún así, la proporción de píxeles que tiene el 1 frente al 3 es del 27% mientras que, entre el 3 y el 8 es del 57%. Lo cual indica que el primero grupo es más distinguible que el segundo, como se observa en la Figura 5, con la comparación entre el 1 y el 3. Este último mantiene su forma, mientras que la comparación entre el 3 y el 8 se ve afectada.

c) Para observar cómo podían variar las imágenes de una forma más general, se decidió tomar dos píxeles significativos de la clase 0 - 627 y 125 -, alejados entre sí para capturar distintos comportamientos pero que ambos cumplen la cualidad de tener los promedios más altos de intensidad considerando todas las imágenes a la vez.

En principio, se ve que tanto la mediana como la media tienen valores similares. También se tiene que ambos tienen un Rango Intercuartil (IQR) similar. Esto indica que en el 50% de los datos, los dos píxeles se encuentran en un rango de intensidad de entre 125 y 175. Este rango equivale al 20% de las intensidades posibles. En el bigote superior se observa que hay datos que llegan a prácticamente el máximo, mientras que en el inferior hasta 25, dando un rango de 230. Por lo tanto, si bien el rango que toma entre todos los datos es muy alto, hay una clara tendencia a parecerse, lo cual se puede ver con la simetría que forman sus histogramas, donde se ve mejor como al formarse el IQR en la mitad del rango; la mediana y la media toman un valor similar debido a una distribución esperada. Es decir, no son el resultado de una distribución con concentraciones en los extremos.




Figura 6: Boxplot de distribución de intensidades de los píxeles con mayor promedio de intensidad de la clase 0 (derecha) y su versión en histograma (izquierda).

d) Si. La principal diferencia se encuentra en que los datasets de las clases eran datos concretos como sexo, edad, precio de pasaje, etc. En cambio, al trabajar con imágenes, sucede que existe una variabilidad entre cada imagen que no solo tiene que ver con el número a representar. Además de que algunas personas puedan hacer los números diferentes, lo que ya implica que todos los datos a estudiar sean objetivamente distintos, también puede suceder que, aunque dos números representados sean parecidos, la tonalidad sea totalmente distinta, y todo por el simple hecho de que la imagen pudo ser capturada con más luz ambiente o con

cierto ángulo de la cámara. Esto genera que se vuelvan datos más complejos de analizar para los cuales hacen falta medidas de tendencia para poder ser estudiados.

## Clasificación binaria:

a) Este nuevo subconjunto contiene 14.780 muestras, donde 6903 corresponden a la clase cero y 7877 al uno. Evidentemente las muestras no están balanceadas. Esto podría ser perjudicial para la exactitud de nuestros resultados con el modelo de KNN porque la clase mayoritaria será más probable que sea vecina, imponiendo su categoría en todas las predicciones. Sin embargo, esto no ocurrirá notoriamente ya que la diferencia es mínima. Este gráfico lo demuestra:




Figura 7

b) En esta parte simplemente se usó la función “train\_test\_split”.

c) En este inciso se empezó por comprobar cuáles eran los píxeles que diferenciaban a los ceros de los unos y viceversa, es decir los píxeles que funcionan como identificador de las clases respecto a nuestro conjunto de datos. Para ello se calcularon los promedios de intensidad por píxel para cada clase, se eliminaron las medias menores a 140 ya que no aportan información relevante y se comparó cuáles eran efectivamente los píxeles identificantes. Estos fueron los resultados:




Figura 8

Figura 9

Como era esperable, la clase 1 se diferencia por el centro, donde los ceros tienen píxeles negros y los unos siempre tienen un trazo. En cambio, los ceros se distinguen por sus porciones superiores e inferiores.

Ya con esta información computada, se entrenaron 15 modelos de KNN a partir de solo 3 píxeles de los característicos de la clase 0 y otros dos modelos a partir de 9 píxeles de este mismo conjunto. Con ellos se calcularon métricas como exactitud, precisión y recall. Los primeros 15 modelos son los asociados a 3 píxeles y los dos últimos a 9. Estos fueron los datos obtenidos:

**Métrica de exactitud por modelo**




Figura 10

**Métrica de precisión por modelo**




Figura 11

**Métrica de recall por modelo**




Figura 12

A nivel general, no se puede identificar ninguna desigualdad extrema en ninguna de las métricas, las diferencias no son notoriamente grandes. De todas formas, un atributo que se mantiene en los tres gráficos es que los modelos entrenados con 9 píxeles obtuvieron mejores métricas como era esperable, dado que estos tienen más información para poder distinguir los dibujos. Por ejemplo se destacaron en la exactitud, es decir que son más capaces de diferenciar las clases, más concretamente los verdaderos negativos y verdaderos positivos (TN y TP). Del subgrupo instruido con 3 píxeles, se destacan los modelos 14 y 15 que consiguieron las mejores métricas de exactitud, precisión y recall (exhaustividad). A pesar de que fueron entrenados con mucha menor información, sus resultados son bastante similares a los del modelo 16 y 17, la diferencia es de apenas  $\pm 0,15$  puntos. Se podría concluir que para este problema de clasificación no existe un trade-off significativo entre precisión y recall, pues para un mismo modelo su recall es casi igual a su precisión. Este fenómeno podría estar ocurriendo debido a que los píxeles que elegimos para entrenarlos diferencian casi perfectamente los unos de los ceros en nuestro conjunto de datos y que la cantidad de vecinos definida debería ser la óptima, por lo tanto el modelo no debe hacer ningún compromiso significativo entre precisión y recall. Esto se suma al hecho de que las muestras están casi balanceadas.

La última aclaración que cabe aclarar es que para este problema de clasificación no tendría sentido buscar una mejor precisión a costa de la exhaustividad o viceversa, porque no existe ninguna necesidad de evitar los falsos negativos o los falsos positivos (FN o FP), los dos tienen la misma importancia. En consecuencia, tendría más sentido quedarse con los modelos que obtengan mejor F1-score que le da la misma importancia a las dos métricas anteriormente nombradas.

d) Antes de empezar con el ejercicio es pertinente explicar que es el sobre y subajuste. El primero hace referencia a cuando los modelos se amoldan demasiado al conjunto de datos de entrenamiento, tomando el ruido como datos relevantes y perdiendo capacidad de predicción. Esto generará malos resultados cuando se lo testeé con el conjunto held out y puede ser producido por una mala elección de hiperparámetros. Contrariamente, el subajuste ocurre cuando las predicciones del modelo son demasiado generales y no es capaz de predecir correctamente patrones un poco más complejos. Sucede también por una mala designación de hiperparámetros y/o cuando hay un excesivo ruido en el conjunto de entrenamiento.

Para este experimento se decidió arbitrariamente entrenar los modelos con tres cantidades de vecinos y atributos distintas. Para los hiperparámetros se eligieron los valores 1, 10 y 30, con la lógica de generar subajuste con  $k=1$ , sobreajuste con  $k=30$  y un valor intermedio con  $k=10$ . Para el caso de los atributos, se entrenó los modelos con 1, 5 y 10 píxeles. De esta forma hay modelos que tendrán muy poca información y otros que tendrán muchas más en comparación. Los píxeles seleccionados fueron los mismos del inciso c). El experimento alcanzó estos resultados:





Figura 13



**Métrica de exhaustividad por modelo separados por cantidad de vecinos (k) y cantidad de atributos (a) de entrenamiento**



**Métrica de precisión por modelo separados por cantidad de vecinos (k) y cantidad de atributos (a) de entrenamiento**




Figura 14 y Figura 15

Como es apreciable, los resultados para todas las métricas son similares. Estos se distinguen en únicamente  $\pm 0,1$  puntos. Nuevamente se puede observar que no existe el trade-off anteriormente explicado y esto ocurre porque los modelos fueron entrenados con el mismo conjunto de datos que en el c). Lo más destacable de este experimento es que, el hecho de haber impuesto cantidades de vecinos muy distintas, no afectó las métricas entre los modelos que fueron entrenados con la misma cantidad de atributos. Por ejemplo, los modelos 3, 6 y 9 consiguen métricas idénticas teniendo un k muy distinto. Análogamente, la cantidad de atributos asignada a cada modelo tampoco modificó ampliamente los resultados obtenidos entre los modelos con misma cantidad de vecinos. Este es el caso de los modelos 1, 4 y 7.

## Clasificación multiclase:

Al momento de separar en el conjunto de desarrollo y el de validación se consideró separarlo en 80% en el desarrollo y 20% en evaluación ya que en el data frame original se usaron 10.000 casos como evaluación y 60.000 como desarrollo, eso daba una división del 85,71% desarrollo y 14,29% de evaluación, por lo tanto las dos opciones más viables y fidedignas en cuanto a la fuente de datos original era trabajar con una muestra de desarrollo entre el 90% o el 80%. Se optó por trabajar con la segunda opción porque se valoró que, al haber un muy leve desbalance de clases con este volumen de datos, bastaría usar el 80% de estos para predecir correctamente cada dígito y el otro 20% que sea para evaluar para así haya una muestras representativa para cada clase.

En cuanto a que datos volcar en el data frame de desarrollo y evaluación, se estimó por un tema de eficiencia optar por no considerar aquellas columnas que contengan pixeles no relevantes en consideración al trabajo realizado en el análisis exploratorio, debido a que parte

de estos pixeles solo daran informacion inutil que no representa la distinción entre los distintos dígitos.




Figura 16: Puntaje de métrica vinculada a la profundidad del árbol

Al momento de entrenar distintos modelos de árboles de clasificación se dividieron estos según el hiperparámetro de profundidad, generando 10 árboles distintos y, basando el análisis en el valor de las métricas, se concluye que el árbol con profundidad 10 es el modelo a elegir entre estos. La elección fue así ya que por un lado obtuvo la mejor puntuación en cuanto a las 3 métricas y, además, al no obtener como resultado 1 en exactitud o un valor muy cercano a éste, de hecho lejano, se descarta la posibilidad de que hubo un sobreajuste en el modelo, es decir que no perdió capacidad de predicción.

Siguiendo con la clasificación multiclase, al momento de testear el valor en las 3 métricas en cuanto a la predicción que tuvo el árbol ya desarrollado en comparación al conjunto de datos de validación se obtuvo que predijo correctamente en una escala de 0 a 1:

- Exactitud del árbol en comparación al held out: 0.6458
- Precisión del árbol en comparación al held out: 0.6463
- Recall del árbol en comparación al held out: 0.6418

Por lo tanto, el árbol de clasificación multiclase predice con una exactitud del 64,58% los dígitos escritos a mano. Se intuye que el porcentaje no es muy alto debido a que:

El árbol, al clasificar por varias clases, necesita una profundidad mayor a la que necesitaría un árbol binario para alcanzar un valor de exactitud alto, debido a que, si bien son 10 clases por lo visto a lo largo del informe y no es necesario tener todos los píxeles del conjunto de datos para realizar una correcta predicción, si se necesitan varios para determinar el dígito y al solo realizar la comparación a esta profundidad no podemos contemplar todos estos teniendo un porcentaje de mejora en cuanto predicción.




Figura 17: Matriz de Confusión de los dígitos bien y mal predichos

Se debe considerar que como existe un desbalance en la cantidad de muestras de cada clase, no debe guiarse directamente de acuerdo a lo que proporciona la diagonal de la matriz de confusión o los demás recuadros. Para esto se seleccionó la cantidad de muestras que tomó el conjunto de datos de validación del árbol de clasificación para cada clase:




Figura 18: Cantidad de representaciones de cada dígitos evaluadas

Posteriormente se observó la tasa de éxito, dividiendo la diagonal de la matriz de confusión (valor predicho que concuerda con valor verdadero) sobre la cantidad de muestras por clase obteniendo:




Figura 19: Tasa de éxito de dígitos acertados en escala de 0 a 1

Puede observarse como el 1 fue el dígito que mejor predijo. Le siguen el 0 y 7 en donde cabe destacar que en particular al 0 nunca se lo predijo como 1 incorrectamente, y a la hora de predecir el 1 fue predicho como 0 la menor de las veces confundiendo más con otras clases. Esto muestra como el 1 y el 0 son los que más se diferencian entre sí.

Por otra parte, cabe destacar como el 9, 5 y 8 fueron los que obtuvieron menor predicción exitosa, en donde el 8 fue confundido con la mayoría de los dígitos sin resaltar sobre los demás alguno en particular. Esto se debe a que el 8 es el dígito que mayor cantidad de píxeles utiliza haciendo que todo el resto de clases sean más probables de ser predichos a la hora de su identificación.

En cuanto al 9 se puede observar que se confunde en su mayoría al 4 y 7; en tanto el 5 aunque parece ser el peor predicho en la matriz de confusión por su diagonal, la verdad es que contaba con una muestra menor respecto a las demás clases siendo cierto que es la tercer peor clase predicha mas no la peor, salvando esto puede observarse en la figura 17 con qué dígitos se confunde más el 5, como puede ser el 3 que fue con el que más tuvo similitudes.

## Conclusiones:

Se concluye en que la fuente de datos podría ser optimizada al contener más de la mitad de los datos como no relevantes, los dígitos según el umbral que se le imponga a la intensidad de sus píxeles se podrán distinguir más fácilmente y se requerirán más o menos píxeles de estos y por último no se logra una buena predicción obteniendo una exactitud del árbol en comparación al held out del 64.58%, esto es debido a que es un árbol de multiclase y haberle pasado tantos datos con esta profundidad, en cambio un árbol con mayor profundidad o con datos filtrados, como los píxeles a considerar de cada dígito junto a su tonalidad hubiera podido lograr una mejor predicción.